

ML examinering - Jakob Ohlsén S.

Svensk Fastighetsanalys behöver hjälp NU! De vill använda sig av Machine Learning i sina värderingar av bostäder, baserat på en rad olika variabler såsom hur stor bostaden är, vilket område bostaden ligger i, hur medianinkomsten är i området etc etc. Därför har jag valt att göra en ML regression, för att kunna förutsäga en bostadsvärdering. Detta var mitt tillvägagångssätt.

❖ EDA

- Saknade värden i total_bedroom: Lom den starka korrelationen mellan total_bedrooms och 3 andra variabler så valdes IterativeImputer för att fylla i de saknade värdena (fyller i värden baserat på de starkt korrelerade övriga variablerna).
- Stark korrelation mellan bostadsvärde och medianinkomst

❖ Machine-Learning

- Train/test split: Vi har vår totala insamlade data, men för att veta om vår modell är bra/dålig så splittar vi upp datan i två delar – en träningsdata och en test-data. Träningsdatan är det modellen får öva på, och testdatan är vårt "prov" där vi får se om vår modell faktiskt har blivit duktig på att förutsäga bostäders värde.
- Delade datan med train_test_split funktionen där jag satte test datan till 20% av vår totala datamängd.

❖ Prövade modeller och utvärdering -

- För att hitta den bästa modellen för att förutsäga bostadspriserna valde jag att testa och jämföra fyra olika algoritmer. Min grundtanke var att jämföra tre linjära modeller som hanterar datan på lite olika sätt, mot en kraftfullare icke-linjär modell.
- Random forest
 - Vår data innehåller geografiska koordinater (latitud och longitud). Linjära modeller fattar i regel noll av sånt – de förstår inte att en viss specifik kombination av latitud och longitud betyder "svindyrt område vid kusten". Därför ville jag slänga in Random Forest. Den bygger på en massa beslutsträd och är bra på att hitta just sådana här kluriga, icke-linjära samband i datan. Som en bonus bryr den sig inte nämnvärt om extremvärden (outliers) i priserna.
- Ridge
 - I vår data har vi flera variabler som korrelerar starkt med varandra (till exempel total_rooms och total_bedrooms). Om man kör en helt vanlig linjär regression på sådan data kan modellen bli väldigt instabil och "snurrig". Ridge löser detta genom att lägga på ett straff (L2-regularisering) som krymper värdena så att modellen inte överanpassar sig (overfittar) till vår träningsdata. En stabil och trygg bas-modell helt enkelt!
- Lasso
 - Lasso är lite cool för den har en inbyggd funktion för att städa upp i datan. Till skillnad från Ridge så kan Lasso ta variabler som är mindre viktiga och krympa deras betydelse till exakt noll. Jag valde den här modellen för att se om vi kunde filtrera bort "brus" i datan och få fram exakt vilka variabler som faktiskt är viktigast för att bestämma huspriset (spoiler: medianinkomst är en av dem!).

- ElasticNet
 - Det här är typ den perfekta kompromissen! Lasso är bra på att ta bort onödiga variabler, men den har en svaghet: Om två variabler är väldigt lika varandra tenderar den att bara behålla en och kasta den andra lite på måfå. ElasticNet kombinerar fördelarna från både Ridge och Lasso. Den kan hantera våra starkt korrelerade variabler på ett bra sätt, samtidigt som den rensar bort det som är helt onödigt.
- Utvärdering
 - MSE-poäng: När det var dags att "rätta provet" och se hur bra modellerna faktiskt presterade valde jag att utvärdera dem mot en metric som heter **MSE** (Mean Squared Error). Den mäter hur stort fel vår modell gör i sina gissningar, men den har en speciell egenskap: den kvadrerar felet. Stora fel ska straffas!
- ❖ Resultat
 - Random Forest vann med lägst MSE-poäng när vi jämförde modellerna på träningsdatan. (2,4 miljoner MSE vs 4,7+ miljoner MSE för övriga modeller)
 - När Random forest fick möta vår DummyRegressor (som bara gissar på medelvärdet för alla datapunkter) så presterade Random Forest 3gr bättre än vår DummyRegressor.
 - Test-Prestanda: Random Forest gissar i snitt fel med 15% (39 579 dollar)
- ❖ Rekommendation
 - Använt Random Forest på ny data för att förutsäga bostadspriser i området baserat på insamlade variabler!
- ❖ Risker och begränsningar
 - Pristak: I datasetet verkar det finnas ett pristak där alla hus över 500 001 dollar klumpas ihop. Detta gör att vår modell kommer ha väldigt svårt att värdera ultra-lyxhus korrekt, eftersom den inte har fått öva på sanna lyxpriser.
- ❖ Övervakad inlärning
 - Övervakad inlärning (Unsupervised Learning) är när vi kastar in data i en algoritm *utan* att ge den ett facit. I vår regression hade vi huspriset som facit, men här får algoritmen leta efter egna, dolda mönster och grupperingar i datan. Det är relevant för Svensk Fastighetsanalys om de till exempel vill hitta "tvilling-områden" – bostadsområden som liknar varandra rent demografiskt eller geografiskt, utan att man nödvändigtvis bryr sig om just priset i första steget.
 - PCA: Att reducera antalet variabler baserat på variablernas korrelation med varann. Detta görs delvis för att undvika att resultatet blir utsatt för multikollinearitet.
 - I Vårt fall kan det vara relevant ifall vi vill reducera mängden variabler, exempelvis vi vill ha en enda variabel som reflekterar storleken på huset, och den variabeln blir då en PCA variabel, som exempelvis består av total_rooms, total_bedrooms, population, households.
 - Klustering med KMeans: Denna modell skapar en viss mängd förinställda kluster, och kollar på variablerna och ser vilket kluster variabeln är närmst. Detta görs med samtliga inmatade variabler tills alla variabler tilldelats ett kluster, och på så sätt har man skapat flera olika kategorier i ens data. Detta var vad jag använde mig av i det här fallet då jag ville se om man kunde skapa ekonomiska och geografiska kluster i vår data.

- ❖ Resultat: Med tanke på vår Elbow så drog jag gränsen vid 3 kluster där jag matade in de geografiska koordinaterna och medianinkomsten. Vårt resultat visade "Norra medelklassen" och "Södra medelklassen" samt även områden där "Övre medelklassen" höll till.
- ❖ Reflektion:

Vad gick bra och vad var svårast? Jag är riktigt nöjd med min inledande datahantering (EDA). Istället för att bara radera rader med saknade värden i `total_bedrooms` eller bara använda medelvärdet för att fylla i de saknade raderna så använde jag `IterativeImputer`. Eftersom jag såg att variabeln korrelerade starkt med andra variabler kändes det som en mycket smartare och mer realistisk lösning. Jag tycker också att det gick bra att knyta ihop resultaten med affärsnyttan för Svensk Fastighetsanalys.

Det som var absolut klurigast i projektet var att få grepp om de olika utvärderingsmått när man ställde modellerna mot varann, samt att ha koll på de olika hyperparametrarna som alla de olika modellerna använder sig utav.

Betygsambition: Jag anser att min inlämning motsvarar ett VG. Jag har uppfyllt alla grundkrav (G) genom att sätta upp ett komplett ML-flöde, göra en korrekt train/test-split, utvärdera mot en relevant metric (MSE) och lyfta fram risker (som pristaket på 500k).

Utöver detta anser jag att jag når VG-kriterierna eftersom jag:

- Inte valde enklaste vägen i datavätten, utan implementerade en avancerad imputering baserad på korrelation.
- Implementerade oövervakad inlärning (K-Means): Elbow-metoden för att hitta optimala kluster, klustrade sedan och tolkade därefter resultatet geografiskt/ekonomiskt för att skapa extra affärsvärde för kunden.